



DEPARTAMENTO
DE COMPUTACION

Facultad de Ciencias Exactas y Naturales - UBA

Trabajo Práctico Grep

31 de Octubre de 2025

Lenguajes Formales, Autómatas y Computabilidad

Integrante	LU	Correo electrónico
Mateo Ziffer	282/24	mateoziffer@gmail.com
Nazareno Olazarri	1017/23	Nazareno_Olaz@hotmail.com
Martín Kraisman	1305/23	martin.kraisman@gmail.com
Completar Nico	LU	Mail



Facultad de Ciencias Exactas y Naturales
Universidad de Buenos Aires

Ciudad Universitaria - Pabellón I

Intendente Güiraldes 2160 - C1428EGA

Ciudad Autónoma de Buenos Aires - Argentina

Tel/Fax: (54 11) 4576-3359

<http://exactas.uba.ar>

1. Decisiones de diseño

Al inicializar la clase `Regex` generamos su AFD mínimo respectivo y lo guardamos en un nuevo atributo llamado `_afd` para luego al hacer cada `match` poder usarlo y no tener que generarlo cada vez.

Para varios de los algoritmos que implementamos decidimos usar los sets de Python. Aunque estos sets tienen limitaciones, específicamente que no se pueden crear sets de sets, y que no se puede iterar un set y agregar o sacar valores en el medio de la iteración, por esto utilizamos cuando es necesario los frozensets, conjuntos cuyos elementos no son modificables.

Decidimos tratar a los autómatas como inmutables luego de inicializarlos así que en determinar, en minimizar y al sacar los estados inaccesibles creamos nuevos autómatas en vez de modificar los ya existentes.

2. Eleccion de algoritmos

Al generar el AFND a partir de la expresión regular utilizamos el algoritmo de Thompson basandonos en la inducción del teorema visto en clase. Se puede decir que en la implementación extendemos el invariante con tener los estados del autómata normalizados en cada paso.

Para hacer la minimización, vimos en clase los algoritmos de Moore, Brzozowski y de Hopcroft. De estos usamos el de Hopcroft porque tiene la mejor complejidad temporal, $O(ns \log n)$ y porque se basa en hacer operaciones entre conjuntos, las cuales ya tenemos implementadas con los sets de Python. Este algoritmo requiere que el autómata no tenga estados accesibles, por lo tanto agregamos un método `minimize` a la clase AFD que primero crea un autómata equivalente sin estados inaccesibles y luego aplica al algoritmo de Hopcroft sobre el mismo.

3. Benchmarks

Para comparar nuestra solución con la naive decidimos utilizar la expresión regular $r = a^*$, sobre el alfabeto $\Sigma = \{a, b\}$. A continuación mostramos el tiempo que tardaron en ejecutarse ambos programas con cadenas aleatorias sobre Σ^* de longitudes 10, 100 y 1000 y con cantidades de cadenas 10, 100, 1000 y 10000, en milisegundos. Las columnas indican la cantidad de cadenas y las filas indican las longitudes de las cadenas.

Solución naive

	10	100	1000	10000	100000	1000000
10	65ms	76ms	80ms	110ms	513ms	4.47s
100	71ms	74ms	114ms	444ms	4.31s	37.24s
1000	69ms	127ms	585ms	5.16s	49.32s	8min 34s

Nuestra solución

	10	100	1000	10000	100000	1000000
10	68ms	73ms	74ms	81ms	214ms	1.20s
100	68ms	65ms	78ms	91ms	199ms	1.29s
1000	71ms	71ms	68ms	95ms	306ms	2.91s

Para generar cadenas aleatorias creamos un programa en `/tlengrep/cadenas_de_prueba/generar_cadenas.py`, y para correr los benchmarks usamos por ejemplo

```
> time python3 tlengrep.py tests.regexes.r09 cadenas\_de\_prueba/100de1000.txt
```

 corre nuestra solución sobre 100 cadenas de 1000 símbolos

```
> time python3 tlengrep.py -n tests.regexes.r09 cadenas\_de\_prueba/100de1000.txt
```

 corre la solución naive sobre 100 cadenas de 1000 símbolos.

4. Posibles mejoras

Hay dos partes del código en los cuales tenemos una complejidad temporal que no es óptima, pero de todas formas se puede ver en los benchmarks que nuestra solución es mejor que la naive. A continuación detallamos que partes son y cómo las mejoraríamos.

Al copiar los estados de un autómata vemos por cada uno si pertenece al conjunto de estados finales del autómata original, de la siguiente forma:

```
for state in states:
    afd.add_state(state, state in self.final_states)
```

Esto es $O(|Q|^2)$, siendo Q el conjunto de estados del autómata original. Esto lo podemos cambiar para que sea $O(n)$ normalizando los estados, para que sean $q_0, q_1, \dots, q_{|Q|}$. Luego creamos un arreglo `esFinal` de booleanos de longitud $|Q|$ inicializado en falso e iteramos cada $q_f \in F$ y marcamos su índice respectivo en `esFinal`. Finalmente por cada i tal que $0 \leq i \leq |Q|$, agregamos el estado q_i siendo final si `esFinal[i]` es verdadero.

En AFD tenemos un método `add_set_as_state` en el cual empezamos haciendo `''.join(sorted(stateSet))`. Este método nos sirve para nombrar estados al determinar y agregarlos al nuevo autómata finito, por ejemplo si se puede llegar a los estados q_0, q_2 y q_3 , nombrará al nuevo estado "q0q2q3". Es necesario que ordenemos el conjunto porque si no podemos representar un mismo estado en el afd con cadenas diferentes, en el ejemplo anterior también se podría nombrar al estado como "q2q0q3". El problema es que hacer el sort del set de estados es $O(n \log n)$, con n siendo el tamaño del conjunto, si consideramos que comparar cadenas es constante, lo cual no es el caso. De todas formas se puede mejorar, primero asumiendo que los estados están normalizados, luego creando un arreglo con los índices que representan los estados que son enteros no negativos y haciendo counting sort sobre este en $O(n)$. Luego se puede convertir los números a strings y finalmente `'q'.join(sortedArray)`. De esta forma pasamos de $O(n \log n)$ a $O(n)$.